


PCA主成份分析

主成份分析是一种统计方法,通过正交变换将一组可能存在相关性的变量转换成一组线性无关的变量,达到数据压缩的目的。



在二维条件下,PCA的目的是找到一个方向,使得数据在这个方向上投影后的方差最大

PCA的目的是通过这一堆数据的坐标,算出这个投影方向 a ,进而算法这些数据在这个方向上的投影

用数学来定义PCA的流程

设 $x_1, x_2, \dots, x_N$ 为训练样本,每个为 N 维寻找一个 $M \times N$ 维矩阵 A ,使 $Y = A(X - \bar{X})$,将 X 的维度由 N 降到 M

PCA的要求:

① $A = \begin{bmatrix} a_1 \\ \vdots \\ a_m \end{bmatrix}$, 其中 a_i 为 $1 \times N$ 维 ② $a_i a_j^T = \begin{cases} 1 & i=j \text{ 时} \\ 0 & i \neq j \text{ 时} \end{cases}$, 即正交性。

③ 方差最大

(a) 寻找 a_1 , st. $\sum_{i=1}^P \|a_1 (x_i - \bar{x})\|^2$ 最大 即 $\text{maximize } \sum_{i=1}^P \|a_1 (x_i - \bar{x})\|^2$.

将公式展开 $\text{maximize } \sum_{i=1}^P a_1 (x_i - \bar{x}) (x_i - \bar{x})^T a_1^T = a_1 \sum a_1^T$

subject to $a_1 a_1^T = 1$ 其中 $\Sigma = \sum_{i=1}^P (x_i - \bar{x}) (x_i - \bar{x})^T$ 为协方差矩阵。

利用拉格朗日乘子法 $E(a_1) = a_1 \Sigma a_1^T - \lambda (a_1 a_1^T - 1)$.

$$\frac{\partial E}{\partial a_1} = \Sigma a_1^T - \lambda a_1^T = 0 \rightarrow \Sigma a_1^T = \lambda a_1^T \text{ 而 } a_1 \Sigma a_1^T = a_1 (\lambda a_1^T) = \lambda$$

$\therefore \lambda$ 为的最大特征值, a_1^T 为最大特征值对应的特征向量

(b) 求 a_2 , 满足条件为 maximize $\sum_{i=1}^p \|a_2(x_i - \bar{x})\|^2$

subject to: $a_2 a_2^T = 1$ $a_2 a_1^T = 0$

拉格朗日乘子法: $E(a_2) = a_2 \Sigma a_2^T - \lambda (a_2 a_2^T - 1) - \beta a_2 a_1^T$

$\frac{\partial E}{\partial a_2} = \Sigma a_2^T - \lambda a_2^T - \beta a_1^T = 0$ (由上式 $\Sigma a_1^T = \lambda a_1^T \Rightarrow \Sigma a_2^T = 0$ 因此
此时需要证明 $\beta = 0$)

证明 $\beta = 0$ 先证明 $(\Sigma a_2^T - \lambda a_2^T - \beta a_1^T)^T = 0$

$$a_2 \Sigma^T - \lambda a_2 - \beta a_1 = 0$$

又由于 $\Sigma = \Sigma^T$ 即: $a_2 \Sigma - \lambda a_2 - \beta a_1 = 0$

两边同乘 a_1^T 得: $a_2 \Sigma a_1^T - \lambda a_2 a_1^T - \beta a_1 a_1^T = 0$

$\therefore \lambda a_2 a_1^T - \lambda a_2 a_1^T - \beta = 0 \Rightarrow \beta = 0$ (前面已证出入=0)

因此 λ 为 Σ 的第二大特征值, a_2^T 为 Σ 的第二大特征值对应的特征向量
同理也可得到 a_3 为 Σ 的第三大特征值, a_3^T 为 Σ 的第三大特征值对应的特征向量, 依此类推

PCA算法流程

(1) 对输入的 N 维列向量 $x_1, x_2, \dots, x_p$, 求协方差矩阵

$$\Sigma = \sum_{i=1}^p (x_i - \bar{x})(x_i - \bar{x})^T$$

(2) 求 Σ 的特征值和特征向量, 按照从特征值从大到小分别是

$$\lambda_1, \lambda_2, \dots, \lambda_m$$

根据矩阵理论, 由于 Σ 是半正定阵, 它的特征值都是非负的。

它们对应的特征向量分别为

$$a_1^T, a_2^T, \dots, a_m^T$$

(3) $A = \begin{bmatrix} a_{11} \\ \vdots \\ a_{m1} \end{bmatrix}$ 它是一个 $M \times N$ 维矩阵

$Y_i = A(X_i - \bar{X})$, 其中 $\bar{X}$ 是 X_i 的均值, 即 $\bar{X} = \frac{1}{P} \sum_{i=1}^P X_i$

将 N 维向量 X_i 变为 M 维向量 Y_i ($M < N$)

~~takeaway~~ takeaway:

如果特征数量大且可能在冗余, 用PCA降维, 往往能收到好的效果
这也是PCA在机器学习中广泛运用的原因

PCA需要降维到什么程度呢? 即 Y 的维度 M 如何确定呢?

答: 能量效率原则: 设协方差矩阵总共有 U 个非零特征值, 这些特征值按照从小到大的排列为 $\lambda_1, \lambda_2, \dots, \lambda_U$.

定义第 M 位次的比率 $P_M = \frac{\sum_{i=1}^M \lambda_i}{\sum_{i=1}^U \lambda_i}$

按照能量比例来选择 M exp 占据 99% 能量的 M 值 or 95% 的 M

由于PCA保留数据方差的特性, 用它进行数据降维的效果往往会非常好, PCA被广泛应用于机器学习和数据处理的各种应用中.